

Relatório do Laboratório 3 - Otimização com Métodos de Busca Local

1. Breve Explicação em Alto Nível da Implementação

1.1. Descida do Gradiente

A implementação da descida de gradiente é feita a partir da movimentação na direção contrária ao gradiente obtido, dependendo do valor da taxa de aprendizagem a função pode retornar mínimos locais em detrimento ao mínimo global.

1.2. Hill Climbing

Nessa implementação de Hill Climbing são escolhidos 8 vizinhos os quais é selecionado o que possui menor custo em relação à posição atual. Em seguida, verifica-se se o vizinho de menor custo possui custo menor que a posição atual, se sim a verificação é feita novamente em relação a ele, se não, o ponto de mínimo determinado pela função é o ponto atual.


A vantagem desse método é que não exige o cálculo da derivada e funciona para espaços discretos.

1.3. Simulated Annealing


Implementação semelhante ao hill climbing na qual, no entanto, se estabelece uma “Temperatura” que diminui conforme as iterações ocorrem, de tal modo que, inicialmente, quando a temperatura ainda não é próxima de zero, o movimento ocorra de forma mais aleatória para evitar mínimos locais, e quando a temperatura se aproxima de zero diminui a probabilidade de realizar movimentos que possam piorar o estado atual.

2. Figuras Comprovando Funcionamento do Código


2.1. Descida do Gradiente



2.2. Hill Climbing



2.3. *Simulated Annealing*



3. Comparação entre os Métodos

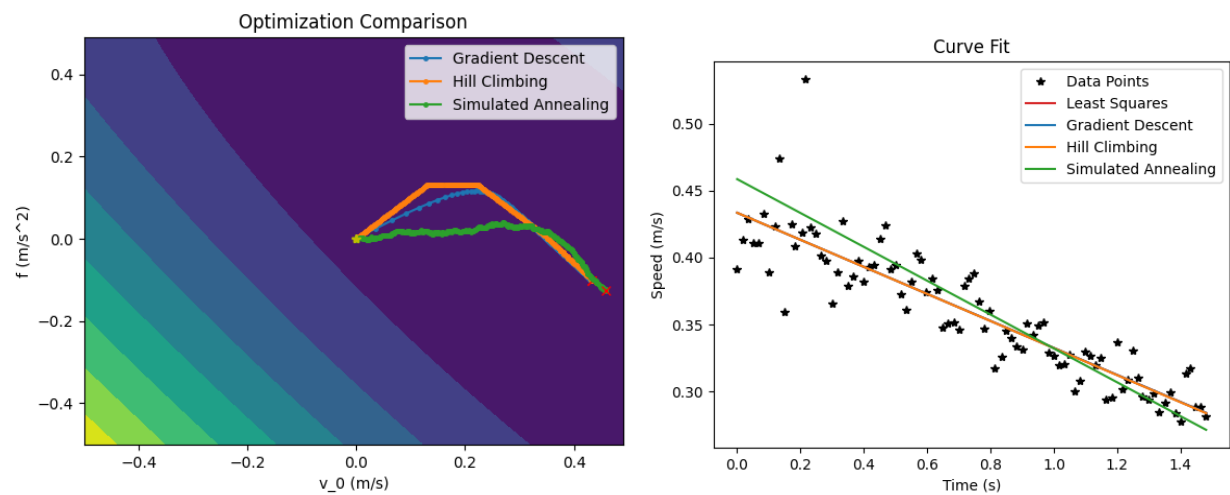


Tabela 1 com a comparação dos parâmetros da regressão linear obtidos pelos métodos de otimização.

Método	v_0	f
MMQ	0.433373	-0.101021
Descida do Gradiente	0.433371	-0.101018
Hill Climbing	0.433411	-0.101196
Simulated Annealing	0.458535	-0.126574

Tabela 1: parâmetros da regressão linear obtidos pelos métodos de otimização.